

[Handbook] Data Cleaning & EDA với Gemini Data Science Agent

Tài liệu này được xây dựng bởi Maz Học Data Team

1. Các Vấn Đề Thường Gặp Khi Data Cleaning và EDA

Vấn Đề Về Thời Gian:

- Mất 2-4 giờ chỉ để clean data cơ bản
- Phân tích EDA thủ công tốn thêm 3-5 giờ
- Viết code từ đầu cho mỗi dataset mới
- Debug và fix lỗi chiếm phần lớn thời gian

Vấn Đề Về Chất Lượng:

- Sót các bước cleaning quan trọng
- Không nhận diện được outliers ẩn
- Thiếu phân tích sâu về missing data patterns
- Bỏ qua relationships quan trọng giữa variables

Vấn Đề Về Kỹ Năng:

- Không biết bắt đầu từ đâu với dataset mới
- Thiếu kinh nghiệm trong việc xử lý các loại data khác nhau
- Khó quyết định cách xử lý outliers và missing values
- Không biết visualize hiệu quả

✅ Giải Pháp: AI-Powered Workflow

Thay vì: Tự viết code và phân tích thủ công **Sử dụng:** AI sinh code tự động dựa trên data structure cụ thể của bạn

Kết quả: 4-6 giờ → 15 phút với chất lượng cao hơn!

2. Hướng dẫn

STEP 1: DATA IMPORT & OVERVIEW

- **Mục Đích Của Bước Đây:**

- **Hiểu cấu trúc data** ngay từ đầu
- **Phát hiện vấn đề sớm** để lập kế hoạch cleaning

⚠ LƯU Ý QUAN TRỌNG: Mô Tả Data

TRƯỚC KHI DÙNG PROMPT, hãy chuẩn bị mô tả data theo columns:

Format mô tả:

Code block

```
1 Dataset: [Loại data - sales/customer/survey/etc]
2 Columns:
3   - Column_name: Mô tả ngắn
4   - Column_name: Mô tả ngắn
5   ...
6 Goal: [Mục tiêu phân tích]
```

Ví dụ mô tả đầy đủ:

Code block

```
1 Dataset: Salary data, columns:
2   - Age
3   - Gender
4   - Education level
5   - Job Title
6   - Years of Experience
7   - Salary
8 Goal: analyse salary trends
```

Quan trọng nhất bạn phải **xác định loại dữ liệu** của bạn là categorical hay numerical.

Code block

```
1 Categorical columns → các cột phân loại, text, ID, tên...
2 Numerical columns → các cột số học, để tính toán, thống kê.
```



Lưu ý: Cần viết đúng tên cột (đúng chữ hoa, chữ thường, dấu cách) như trong file csv.

Ví dụ:

Code block

```
1 Categorical columns:['Gender','Education Level','Job Title']
2 Numerical columns: ['Age','Years of Experience','Salary']
```

Sau khi đã mô tả đầy đủ, bạn điền vào prompt như ví dụ dưới đây.

PROMPT STEP 1:

- Import CSV vào Colab (dùng widget upload).
- Load dữ liệu vào DataFrame.
- Xác định **categorical columns** và **numerical columns** (dựa trên mô tả người dùng cung cấp).
- Convert categorical sang `category dtype`, numerical sang numeric.
- Xuất thông tin tổng quan: `info()`, `shape`, `describe()`, `dtypes`, `head()`, missing values.

Kết Quả Bạn Sẽ Có:

-  Code import data hoàn chỉnh
-  Hiểu rõ cấu trúc và vấn đề của dataset

Code block

```
1 Generate Google Colab code in separate cells to import a CSV file, perform
  data overview.
2 Dataset: Salary data, columns:
3 - Age
4 - Gender
5 - Education level
6 - Job Title
7 - Years of Experience
8 - Salary
9 Goal: analyse salary trends
10
11 Here's a breakdown of the cells I'd like:
12
13 **CELL 1: SETUP & IMPORT**
14 - Import all necessary libraries (pandas, numpy, matplotlib, seaborn, plotly)
15 - Use Google Colab file upload widget to import a CSV file from my local
  machine.
16 - Load the data into a pandas DataFrame.
17 - Define the following columns:
```

```
18 - Categorical columns:['Gender','Education Level','Job Title']
19 - Numerical columns: ['Age','Years of Experience','Salary']
20 - Convert categorical columns to 'category' dtype.
21 - Attempt to convert numerical columns to a suitable numerical type, handling
    errors.
22 - Print the identified categorical and numerical columns.
23 - Display the DataFrame's info().
24
25 **CELL 2: DATA OVERVIEW**
26 - Print the shape of the DataFrame.
27 - Print information about the DataFrame using info().
28 - Print descriptive statistics of the DataFrame using describe().
29 - Print the data types of each column using dtypes.
30 - Display the first 5 rows of the DataFrame using display(df.head()).
31 - Print the column names as a list.
32 - Print the number of missing values per column.
33
34 Make sure to add markdown cells before each code cell to explain the purpose
    of the code block.
```

Trường hợp đặc biệt:

Trường hợp Gemini không cho ra dòng code đầy đủ như bên dưới thì bạn phải tự nhập vào đoạn code.

Trước

Code block

```
1 # Define lists for categorical and numerical columns (assuming example
  # column names)
2 # **Note:** You will need to adjust these column names based on your
  # specific CSV file.
3 categorical_cols = ['categorical_column_1', 'categorical_column_2']
4 numerical_cols = ['numerical_column_1', 'numerical_column_2']
```

Sau

Code block

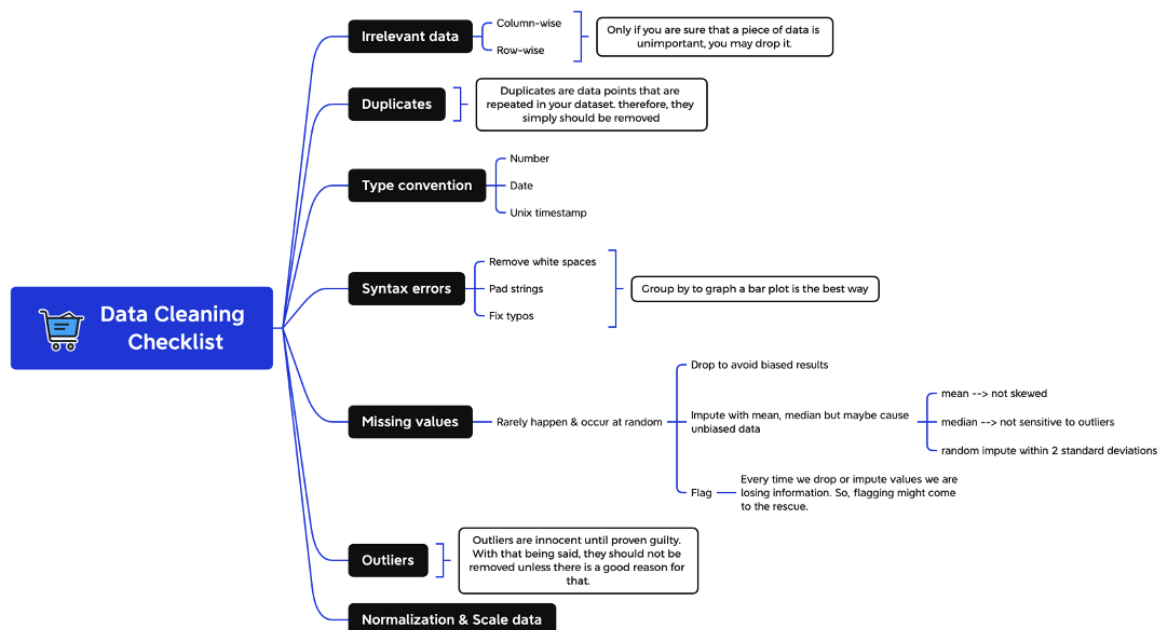
```
1 Categorical columns = ['Gender','Education Level','Job Title']
2 Numerical columns = ['Age','Years of Experience','Salary']
```

STEP 2: DATA CLEANING

Mục Đích Của Bước Đây:

- **Đánh giá chất lượng** tổng thể của dataset
- **Nhận diện outliers** cần xem xét
- **Xử lý outliers** dựa trên business logic
- **Giải quyết missing values** một cách thông minh
- **Chuẩn hóa data formats** để phân tích chính xác
- **Tạo dataset sạch** cho EDA

Data cleaning.



Copyright © Maz Học Data 2025

Nhiệm vụ:

- **Đánh giá chất lượng data & phát hiện vấn đề:**
 - Phát hiện outliers (IQR, Z-score).
 - Visualize outliers bằng boxplot/scatter.
 - Check duplicates, inconsistent format.
 - Phân tích missing data pattern.
 - Xuất báo cáo chất lượng dữ liệu.
- **Điều tra outliers:**
 - Show records outliers để review.
 - Phân tích thống kê, pattern của giá trị cực trị.

- **Xử lý outliers:**
 - Đưa ra nhiều lựa chọn (remove / keep / transform / cap).
 - Dựa trên business logic.
 - Document lại quyết định xử lý.
- **Xử lý missing values:**
 - Tự động xử lý theo kiểu cột.
 - Numerical → impute mean/median.
 - Categorical → impute mode.
 - Ghi log cleaning decisions.
- **Tối ưu & chuẩn hóa:**
 - Convert đúng data type.
 - Parse dates.
 - Chuẩn hóa text (trim, case).
 - Remove duplicates.
 - Normalize/standardize numerical columns.
- **Validation sau cleaning:**
 - So sánh Before vs After.
 - Check kết quả xử lý outliers/missing.
 - Xuất báo cáo chất lượng cuối.
 - Option export dataset sạch ra file.

Kết Quả Bạn Sẽ Có:

-  Dataset đã được clean hoàn toàn
-  Báo cáo chi tiết các thay đổi đã thực hiện
-  Validation kết quả cleaning
-  Dataset sẵn sàng cho phân tích EDA

PROMPT STEP 2:

Code block

```
1 Based on my setup dataset from Step 1, assess data quality, investigate
  outlier if any, treat outlier, missing value and normalize data.
2 Generate comprehensive data cleaning workflow:
3
4 **CELL 1: DATA QUALITY ASSESSMENT & OUTLIER DETECTION**
```

```

5  - Detect outliers using IQR, Z-score methods
6  - Visualize outliers with boxplots and scatter plots
7  - Detect duplicates and inconsistent formats
8  - Missing data patterns analysis
9  - Generate comprehensive data quality report
10
11  **CELL 2: OUTLIER INVESTIGATION**
12  - Show outlier records for business review
13  - Statistical significance of outliers
14  - Pattern analysis of extreme values
15  - Document outliers for cleaning decisions
16
17  **CELL 3: OUTLIER TREATMENT DECISIONS**
18  - Provide multiple options for each outlier: remove, keep, transform, cap
19  - Business-logic based outlier handling
20  - Document all outlier treatment decisions
21
22  **CELL 4: MISSING DATA HANDLING**
23  - Automated missing value treatment based on column type
24  - Imputation strategies for numerical columns
25  - Mode/most frequent for categorical columns
26  - Document all cleaning decisions
27
28  **CELL 5: DATA TYPE OPTIMIZATION & STANDARDIZATION**
29  - Convert columns to appropriate data types automatically
30  - Parse dates if detected
31  - Remove duplicates
32  - Standardize text formatting (trim spaces, case consistency)
33  - Normalize/standardize numerical columns if needed
34
35  **CELL 6: CLEANED DATA VALIDATION**
36  - Before vs after comparison
37  - Validation of cleaning results (including outlier treatment)
38  - Final data quality report
39  - Export cleaned dataset option
40
41  Customize cleaning approach based on my specific data issues and outlier
    findings from Step 1.

```

Điểm Mạnh Của Approach Đây:

- **Tùy chỉnh theo data thực tế:** Không phải generic cleaning
- **Multiple options:** AI đưa ra nhiều lựa chọn cho từng vấn đề
- **Business-focused:** Quyết định cleaning dựa trên business context
- **Validation:** Kiểm tra kết quả cleaning ngay lập tức

STEP 3: COMPREHENSIVE EDA

Mục Đích Của Bước Đây:

- Khám phá **patterns** trong clean data
- Tìm **relationships** giữa các variables
- Tạo **business insights** actionable
- Đưa ra **recommendations** cụ thể

Nhiệm vụ:

- **Univariate analysis:**
 - Phân phối của numerical columns.
 - Tần suất của categorical columns.
 - Summary statistics.
- **Bivariate analysis:**
 - Phân tích tương quan (correlation).
 - Explore relationships giữa các biến.
 - So sánh chéo giữa variables (đã loại outliers noise).
- **Multivariate analysis:**
 - Phát hiện pattern với nhiều biến cùng lúc.
 - Advanced visualization (heatmap, pairplot, segment).
 - Segmentation insights.
- **Business insights:**
 - Tóm tắt key findings.
 - Đánh giá impact của xử lý outliers.
 - Recommendations thực tế cho business.
 - Gợi ý next steps cho phân tích sâu hơn.

Kết Quả Bạn Sẽ Có:

-  Báo cáo EDA hoàn chỉnh với visualizations
-  Key insights và patterns quan trọng
-  Business recommendations actionable
-  Hiểu sâu về data và có thể present cho stakeholders

PROMPT STEP 3:

Code block

```
1  Based on my cleaned and outlier-treated dataset from Step 2, create
   comprehensive EDA code for Google Colab.
2
3  Generate systematic EDA code:
4
5  **UNIVARIATE ANALYSIS**
6  - Distribution analysis for all cleaned numerical columns
7  - Frequency analysis for all categorical columns
8  - Summary statistics on cleaned data
9
10 **BIVARIATE ANALYSIS**
11 - Correlation analysis between all variables
12 - Relationship exploration based on cleaned data
13 - Cross-variable comparisons without outlier noise
14
15 **MULTIVARIATE ANALYSIS**
16 - Pattern discovery across multiple variables
17 - Advanced visualizations on clean data
18 - Segmentation insights
19
20 **BUSINESS INSIGHTS**
21 - Key findings summary from cleaned data
22 - Impact of outlier treatment on insights
23 - Recommendations based on discovered patterns
24 - Next steps for deeper analysis
25
26 Work with my cleaned, outlier-treated dataset for accurate and reliable
   analysis results.
```

Sức Mạnh Của EDA Tự Động:

- **Comprehensive coverage:** Không bỏ sót analysis nào quan trọng
- **Smart visualizations:** Charts phù hợp với từng loại relationship
- **Business interpretation:** Không chỉ có numbers mà còn có insights
- **Actionable recommendations:** Đưa ra next steps cụ thể

Điểm mạnh của AI Agent Gemini vào Colad

Explain error

Explain error

Dựa vào prompt này, bạn không cần phải tốn hàng giờ đồng hồ cho bước tiền xử lý dữ liệu nữa mà có thể nhanh chóng bắt tay vào xem xét dữ liệu như một Data Scientist thực thụ. Không cần phải là chuyên gia về Python hay thống kê để bắt đầu. Bạn chỉ cần hiểu bối cảnh kinh doanh của dữ liệu, biết đặt đúng câu hỏi, và để AI xử lý phần kỹ thuật.

Chúc bạn thành công nhé!

🔥 Nếu mọi người muốn tham khảo thêm các kiến thức liên quan đến Data Analyst thì có thể tham gia vào cộng đồng học tập hoàn toàn miễn phí của Maz. Mình tạo ra cộng đồng này để mọi người có thể giúp đỡ và học hỏi nhau trên con đường làm DA này.

[Home](#)
[Courses](#)
[Leaderboard](#)

Feed

Start a post

Maz Học Data
Admin
3d

Posted in Kiến thức & Tài nguyên

5 BƯỚC TẠO RA DASHBOARD: Đẹp UI/UX – Đủ Insights– Automation

Tuần trước, lớp mình có 1 project khá tốt để làm showcase kỹ năng build dashboard với PBI. Sản tiện mình cũng note lại vài tips khi học & làm dashboard cho các bạn mới nha!

Đầu tiên, hầu hết người tự học xây Dashboard đều mắc phải các lỗi cực kì cơ bản...

See more

Chi Vô Thi Ngọc
3rd

Student at Đại Học Mở Thành Phố Hồ Chí Minh | QA | BA

+ Follow

THÔNG TIN CHUNG

14

1

Course: SQL

Course: Python

Course: Data Analytics 101

8

25

Trending posts

Tổng Hợp Database Uy Tín Cho Người Mới Bắt Đầu
Admin Data Guide

6 Cuốn Sách SQL - Từ Nhập Môn Newbie Đến Tối Ưu Hiệu Năng Cho Chuyên Gia
Admin Data Guide

43 Data Jobs - Weekly Update
Admin Data Guide

[STUDY PLAN SQL CHI TIẾT - 1 Tiếng Mỗi Ngày Chính Phục SQL Trong 2 Tháng]
Admin Data Guide

5 BƯỚC TẠO RA DASHBOARD: Đẹp UI/UX – Đủ Insights– Automation
Maz Học Data